FDP 端侧优化与跨平台对照

2026.09.21 - 09.28 | 从等价优化到候选筛选

01 承接上周：FDP 端侧提速

上周已完成 Orin Docker 部署：Exact 约 4.17 秒且保持原版输出；旧 fast 约 2.89 秒，但部分帧位姿变化超限。本周从 Exact 重新拆解，先提高计算效率，再减少候选计算，目标为 1 秒级定位并控制相对参考的位姿偏差。

A0 原版 — 完整候选计算 → **A1** 等价优化 — 采样与冗余开销 → **A2** 全候选加速 — 微批次与算子选择 → **A3** 分阶段筛选 — 首轮后保留16 → **A4** 竖直先验 — 首轮预选64

A0 / A1 沿用上周起点；A2 / A3 / A4 为本周形成的三条主线方案。共用原 FDP 网络和权重，未重新训练；A4-64 是后续修订方案，见第 2 页。

统一配置复验：耗时与相对 4090 的通过帧数

09/24 · 每方案 28 帧 × 5 次正式

方案	三轮候选数	register 耗时中位数（s）	通过帧
A0 原版	252→252→252	5.801	28/28
A1 等价优化	252→252→252	2.810	28/28
A2 全候选	252→252→252	2.167	28/28
A3 分阶段	252→16→16	1.678	26/28
A4 竖直先验	64→16→16	0.596	27/28



复验参数：120×120 输入、3 轮精修、毫米深度；matmul TF32 关闭，AMP / cuDNN TF32 保持开启。A1 / A2 的 140 次正式输出均与 A0 对应输出完全一致。

阶段判断

A2 保持全部候选，将中位耗时由 5.801 秒降至 2.167 秒；A4 达到亚秒级，但仍有 1 帧超过跨平台偏差阈值，需要进一步修正候选筛选。

统计口径：中心差 ≤10 mm 且逐轴 RPY 差 ≤4°；同帧 5 次全部通过才计为通过帧。耗时为预热后的 register，不含分割、深度前端、通信和初始化；各方案串行运行。

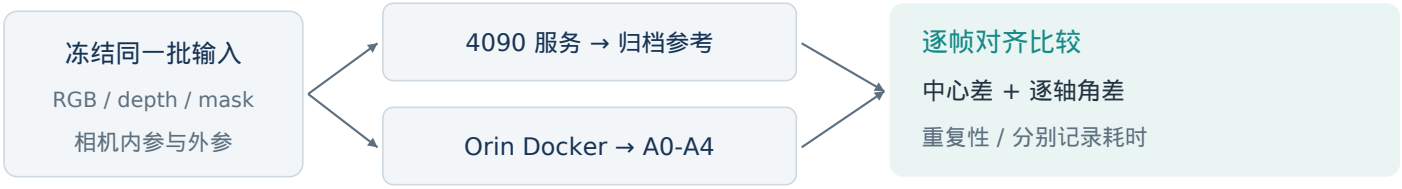
来源：09/20《Orin FDP v9 13帧验证》；09/24《matmul TF32关闭后的A0-A4完整复验》。

FDP 端侧优化与跨平台对照

2026.09.21 - 09.28 | 配置对齐 → TF32 排查 → 候选保留修正

02 跨平台对照与最终修正

为什么快了还不能直接采用？早期 A4 虽相对 Orin 原版全部通过，改用 4090 参考后却出现偏差，连 Orin 原版也仅 23/28 帧通过。因此先核对部署条件，再判断优化本身的影响。



固定 28 帧（D12 / H3 / ChArUco13），完整复验每帧 1 次预热 + 5 次正式；核验输入、权重及 mesh，后续 Orin 实验对照已归档的 4090 同帧输出。

9/22 发现条件不同

160 / 120 输入尺寸

2 / 3 轮、米 / 毫米深度

A0 相对4090：23/28

9/22-23 配置对齐

8组消融后统一为

120×120 / 3轮 / 毫米

A0 相对4090：26/28

9/24 数值路径对齐

定位矩阵乘法TF32差异

关闭 Orin matmul TF32

A0 相对4090：28/28

TF32 修正仅改变矩阵乘法精度开关，AMP 与 cuDNN TF32 保持开启。修正后完整复验中，A0 全部通过，而 A4 保留 16 个候选仍有 C09 一帧超限。

最终修正：候选越少不一定越好

失败帧的关键候选在首轮筛选时被丢弃。保留竖直先验选出的 64 个候选，后两轮不再缩减至 16 个，以少量耗时换回该帧的一致性。

对比指标	A4-16	A4-64 修订方案
三轮候选数	64→16→16	64→64→64
register 中位 / 最大（s）	0.596 / 0.776	0.850 / 0.879
相对4090中心差中位 / 最大（mm）	0.246 / 16.679	0.215 / 7.765
相对4090通过帧	27/28	28/28
低于1秒的正式运行	140/140	140/140
C09 失败帧中心差（mm）	16.679	0.159

本周结果：A4-64 中位 0.850 秒，140 次正式运行均低于 1 秒；28/28 帧全部满足相对 4090 的位置与角度偏差要求。

适用范围：已有近直立箱体数据，4090 为部署参考，并非独立真值。A4-64 为后续独立批次，非同步负载测试；本结果属于离线定位验证。4090 服务 / 客户端与 Orin register 计时范围不同，不作同口径硬件速度排名。

来源：09/22《4090部署对比》；09/24《A0与4090逐阶段对比》《A4候选保留数对照》。